ggplot2

Nicholas A. C. Marino

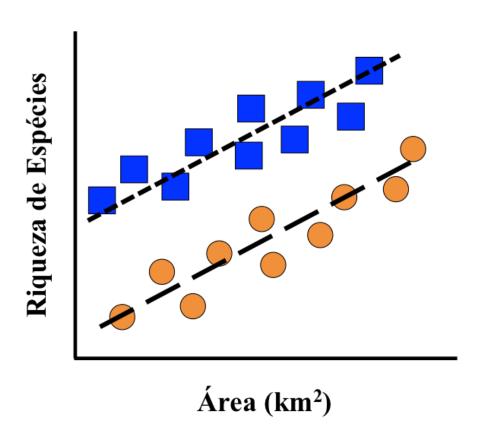
nac.marino@gmail.com

github.com/nacmarino/compartilhaR

Estrutura da Aula

- 1. Gramática dos Gráficos
- 2. ggplot2
- 3. Exportando figuras do ggplot2
- 4. Integrando o ggplot2 ao tidyverse

Como você descreveria a figura abaixo?



Que figura pode ser feita com estes dados?

```
## var1 var2 x y
## 1 a fechado 2.0 1.0
## 2 b fechado 3.0 1.5
## 3 a fechado 2.5 1.4
## 4 b aberto 5.0 4.2
## 5 a aberto 6.0 4.0
## 6 b aberto 5.5 4.6
```

- · Leland Wilkinson desenvolveu a ideia de que todo gráfico pode ser descrito por um conjunto de componentes semanticos:
 - um sujeito, que são as variáveis que queremos colocar no gráfico (*data*, *aesthetics*);
 - um ou mais verbos, que representam de que forma o sujeito será apresentado (*geometries*, *facets*);
 - um ou mais adjetivos, que descrevem características do sujeito (*color*, *fill*, *shape*, *alpha*).
- Ele organizou isto na forma da Gramática dos Gráficos (*The Grammar of Graphics*) um esquema para facilitar e descrever a visualização dos dados.

"Resumidamente, a gramática nos diz que um gráfico deve ser mapeado (mapping) a partir dos dados (data), de acordo com a aparência (aesthetic; color, formato, tamanho) de objetos geométricos (geometric; pontos, linhas, barras). A figura também pode conter transformações estatísticas dos dados, sendo desenhada a partir de um sistema específico de coordenadas." (Do livro "ggplot2")

· Uma figura é desenhada através da sobreposição de diferentes camadas de informações sobre os dados.



- · A ideia principal por traz da Gramática dos Gráficos eé reduzir a distância entre a mente e a página, a ideia e a criação: você desenha, adicionando e modifica as camadas durante o processo de criação da figura.
- Isto traz algumas vantagens:
 - Não é preciso desenhar toda a figura de uma vez só (ao contrário das funcionalidades do pacote lattice);
 - Toda camada adicionada à figura pode ser alterada posteriormente (ao contrário das funcionalidades do pacote base);
 - Criação de figuras complexas com comandos simples e intuitivos (ao contrário dos pacotes lattice e base).

ggplot2

- É a implementação da Gramática dos Gráficos na linguagem de programação
 R.
- É um dos pacotes gráficos mais utilizados, por facilitar muito mais a visualização dos dados quando em comparação com os pacotes base e lattice.
- · Escrito por Hadley Wickham (cientista chefe do RStudio), quando ainda era um estudante de pós-graduação.
- Podemos carregar este pacote usando o próprio nome ggplot2 ou através do tidyverse.

```
library(tidyverse)

# outra opção - usar uma ou outra!
library(ggplot2)
```

Exercício 1

- 1. Importe para o R a tabela de dados das ilhas.xlsx, e atribua esta tabela ao objeto ilhas.
- 2. Carregue o conjunto de dados gapminder disponível no pacote gapminder.

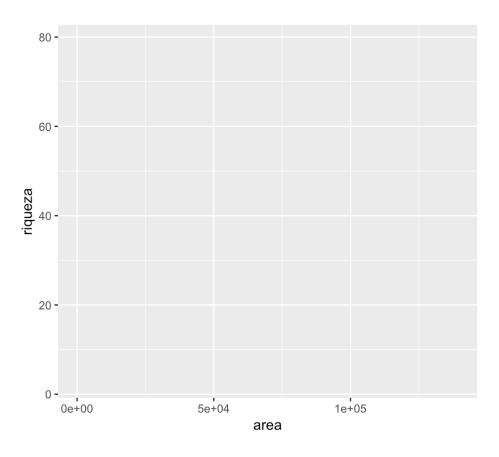
Começando uma figura

- Toda figura criada através do ggplot2 começa da mesma forma: através da função ggplot().
- · Ainda assim, existem duas formas de iniciar uma figura através dessa função, sendo a primeira delas dizendo o que iremos desenhar: mapearemos uma unidade estética que virá de um conjunto de dados.

```
ggplot(data = ilhas, mapping = aes(x = area, y = riqueza))
```

Começando uma figura

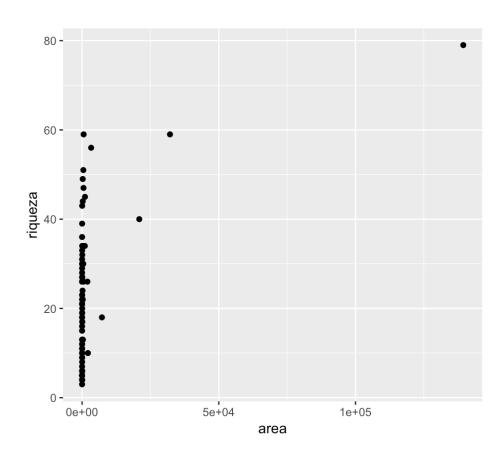
ggplot(data = ilhas, mapping = aes(x = area, y = riqueza))



- · Uma vez que já definimos que unidade **estética** será **mapeada**, precisamos definir de que forma esta relação será representada.
- A representação destas relações é feita através de representações geométricas, que indicam o tipo de figura que gostaríamos de produzir.
- Como queremos adicionar uma representação geométrica à unidade estética que foi mapeada precisamos, literalmente, adicionar uma camada à outra, utilizando o sinal + ao final da linha.

```
ggplot(data = ilhas, mapping = aes(x = area, y = riqueza)) +
  geom_point()
```

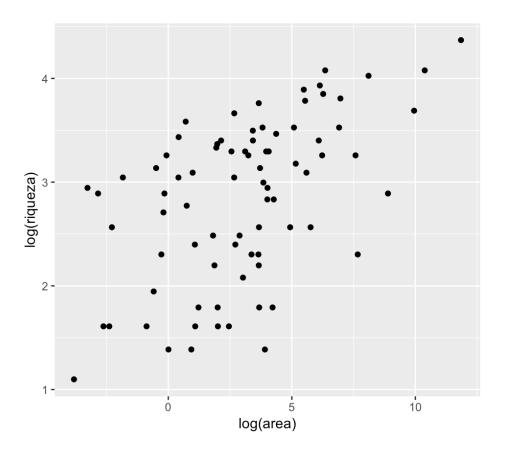
```
ggplot(data = ilhas, mapping = aes(x = area, y = riqueza)) +
  geom_point()
```



- Note, no entanto, que o gráfico sugere uma forte relação não-linear o que é esperado ao plotarmos a área contra a riqueza de espécies em sua escala natural.
- · Assim como outros pacotes, o ggplot2 permite que adicionemos transformações às variáveis que estamos mapeando.

```
ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza))) + geom point()
```

```
ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza))) +
  geom_point()
```



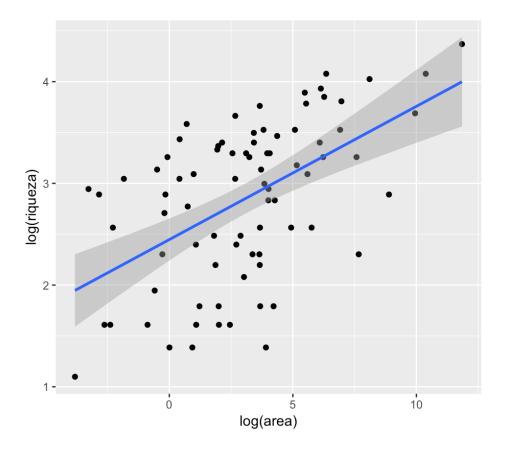
Representando a tendência da relação entre x e y

- Podemos adicionar tantas representações geométricas quanto quisermos à uma figura, desde que faça sentido adicionar uma camada à outra já existente.
- · Por exemplo, podemos adicionar uma representação **geométrica** indicando a tendência da relação entre a área e a riqueza de espécies.

```
ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza))) +
  geom_point() +
  geom_smooth(method = "lm")
```

Representando a tendência da relação entre x e y

```
ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza))) +
  geom_point() +
  geom_smooth(method = "lm")
```

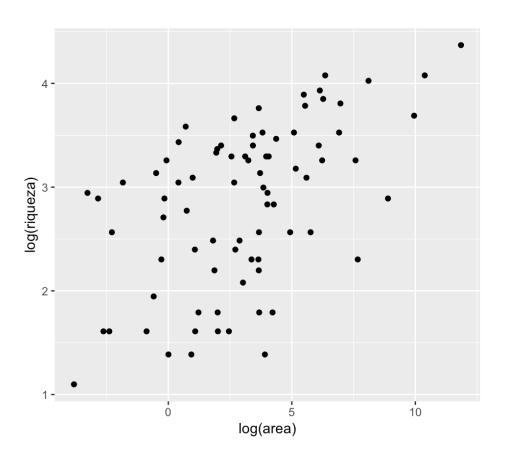


- Uma maneira alternativa a criar uma figura no ggplot2 é começando através de um gráfico em branco, e ir adicionando as informações que queremos mapear camada a camada.
- Todavia, ao utilizar este método será necessário dizer à função quais são os dados e quais são os elementos estéticos que serão mapeados em cada camada.

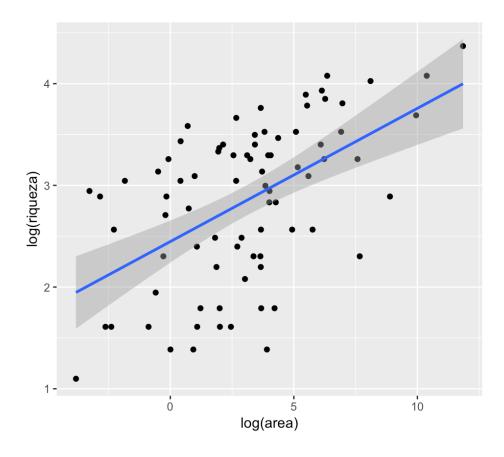
ggplot()

ggplot()

```
ggplot() +
  geom_point(data = ilhas, mapping = aes(x = log(area), y = log(riqueza)))
```

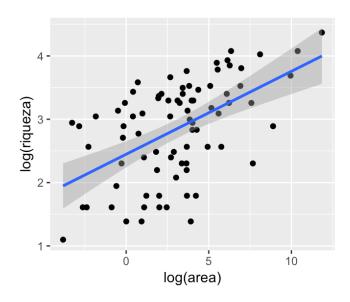


```
ggplot() +
  geom_point(data = ilhas, mapping = aes(x = log(area), y = log(riqueza))) +
  geom_smooth(data = ilhas, mapping = aes(x = log(area), y = log(riqueza)), method = "lm")
```



 Finalmente, uma terceira forma de iniciar uma figura é determinando apenas o conjunto de dados de onde sairão todas as informações, e determinar o que será mapeado em cada camada

```
ggplot(data = ilhas) +
  geom_point(mapping = aes(x = log(area), y = log(riqueza))) +
  geom_smooth(mapping = aes(x = log(area), y = log(riqueza)), method = "lm")
```



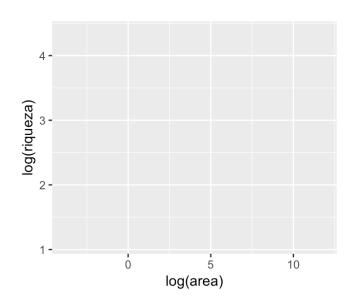
Mapear desde o início ou não?

- Existe uma diferença fundamental na forma como começamos a desenhar um gráfico no ggplot2, que podemos usar ao nosso favor dependendo do objetivo e dados que temos:
 - Especificar apenas o conjunto de dados na função ggplot: útil quando todas as informações que irão para cada geom estão dentro de uma mesma tabela.
 - Especificar o conjunto de dados e a unidade estética dentro da função geom: útil quando cada geom representa informações presentes em conjunto de dados diferentes.
 - **Especficiar o conjunto de dados e a unidade estética dentro da função ggplot:** útil quando toda a figura é feita com referência àquela unidade estética vinda daquele conjunto de dados.
- Dependendo da forma como você escolher desenhar a figura, você pode ter problemas ao definir alguns outros elementos gráficos - falaremos mais sobre isso depois.

Criando uma figura do ggplot2 objeto-a-objeto

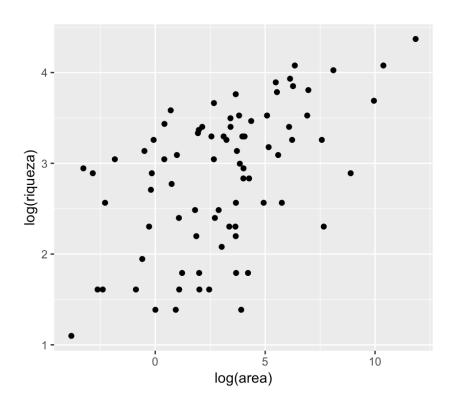
 Não precisamos criar todas as camadas de uma vez ao desenhar uma figura no ggplot2: podemos criar uma camada, atribuir ela a um objeto, adicionar mais uma camada a esse objeto e sobre-escrevelo, e assim sucessivamente.

```
figura <- ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza))) figura
```



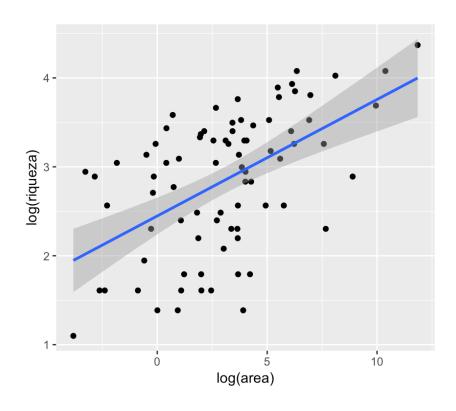
Criando uma figura do ggplot2 objeto-a-objeto

```
figura <- figura +
    geom_point()
figura</pre>
```



Criando uma figura do ggplot2 objeto-a-objeto

```
figura <- figura +
    geom_smooth(method = "lm")
figura</pre>
```



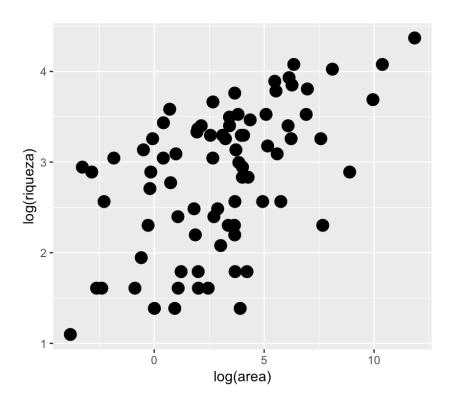
Exercício 2

- 1. Crie uma figura demonstrando a relação entre a riqueza de espécies de mamíferos e a produtividade primária das ilhas.
- 2. Crie um boxplot demonstrando de que maneira a riqueza de espécies varia em função do tipo de ilha.

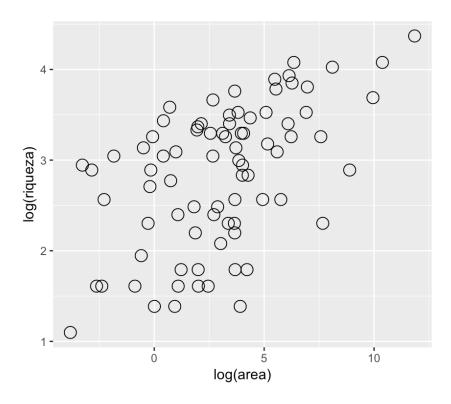
· Assim como nas figuras criadas na base e no lattice, também podemos modificar o tamanho (size), formato (shape), cor da borda (color), preenchimento (fill), grossura da linha dos símbolos (stroke) e das linhas (size), tipo de linhas (linetype) de cada geom.

```
ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza))) +
  geom_point(size = 4)
```

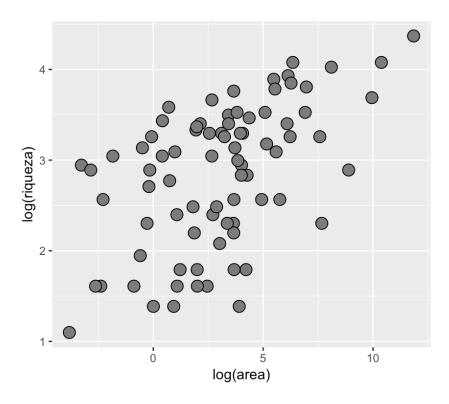
```
ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza))) + geom_point(size = 4)
```

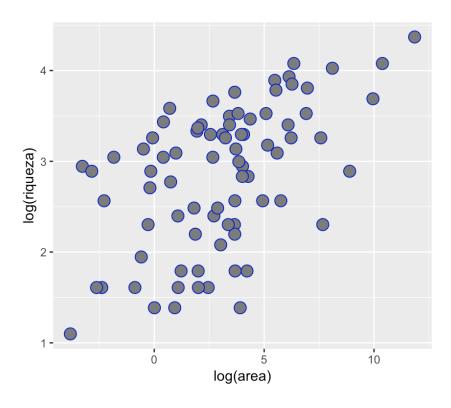


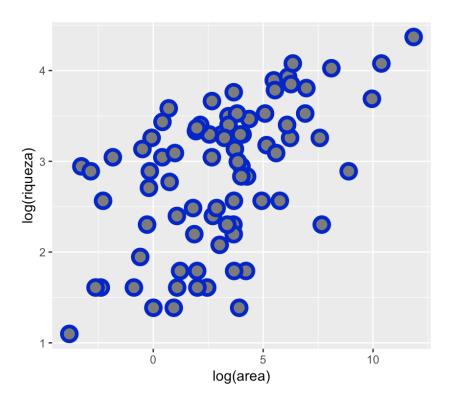
```
ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza))) +
  geom_point(size = 4, shape = 21)
```

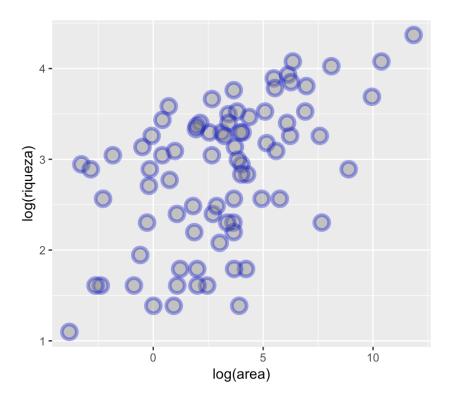


```
ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza))) +
geom_point(size = 4, shape = 21, fill = "grey50")
```









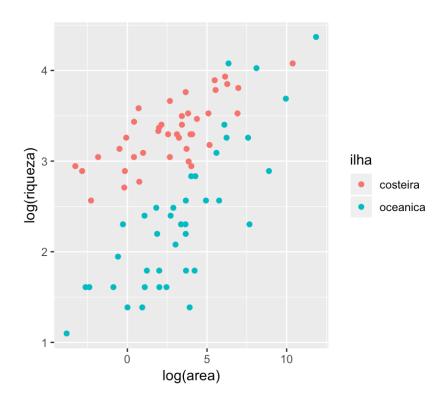
Exercício 3

1. Customize o boxplot que você criou no exercício anterior. Para saber que tipo de customização pode ser feita a esse geom, você pode consular o arquivo de ajuda dele ?geom_boxplot.

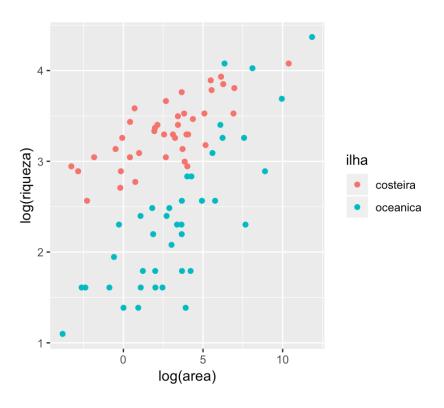
- · Quando fazemos uma análise exploratória dos dados ou até mesmo quando estamos criando uma figura para um trabalho, podemos ter como objetivo demonstrar de que forma múltiplas variáveis afetam a relação entre \mathbf{x} e \mathbf{y} .
- Graficamente, quando fazemos isso na realidade estamos mapeando estas outras variáveis a um dado geom - isto é, fazemos as características deste geom variar em função dos valores destas variáveis.
- Para tal, devemos dizer para o ggplot que todas aquelas características que acabamos de ver para a customização dependem dos valores estéticos que queremos mapear.

```
ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza), colour = ilha)) + geom point()
```

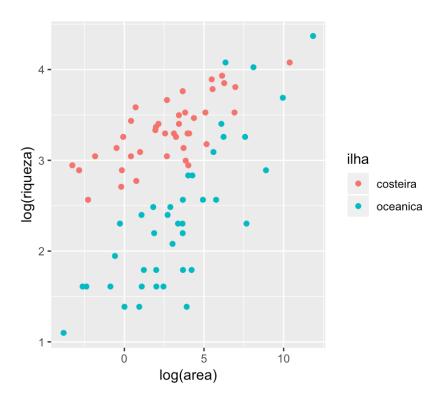
```
ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza), colour = ilha)) +
  geom_point()
```



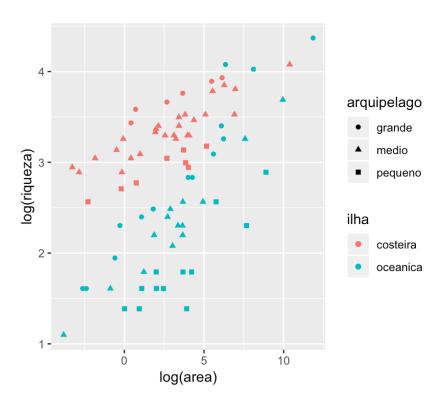
```
# outra forma de fazer isso
ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza))) +
geom point(mapping = aes(colour = ilha))
```

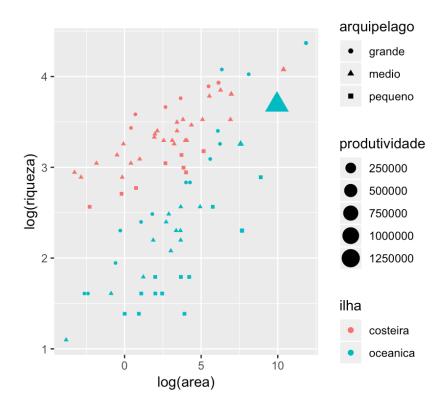


```
# e mais uma
ggplot() +
geom_point(data = ilhas, mapping = aes(x = log(area), y = log(riqueza), colour = ilha))
```



- É importante notarmos algumas coisas ao fazermos isso:
 - A característica que será mapeada à variável deve estar dentro do mapping!
 - O nome da variável que será mapeada a alguma dessas características nunca deve estar entre aspas!
 - Ao definir que variável será mapeada a que característica logo na função ggplot, esta característica será mapeada da mesma forma em todas as camadas que você desenhar!
 - Podemos mapear múltiplas variáveis ao mesmo tempo.

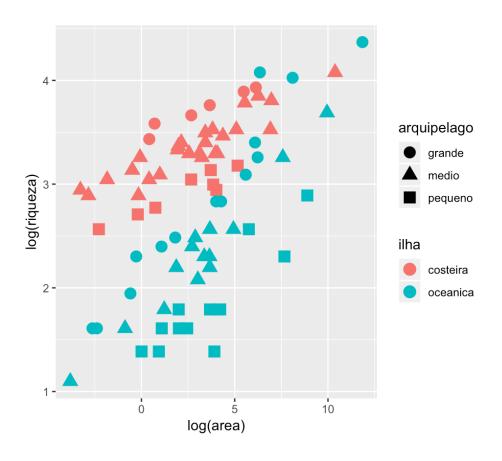




- · Também podemos combinar características mapeadas à variáveis com características mapeadas de forma fixa.
- · Mas não se esqueça: toda característica mapeada a uma variável vai dentro do parenteses, toda característica fixa vai fora dele.

```
ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza))) + geom point(mapping = aes(colour = ilha, shape = arquipelago), size = 4)
```

```
ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza))) + geom point(mapping = aes(colour = ilha, shape = arquipelago), size = 4)
```



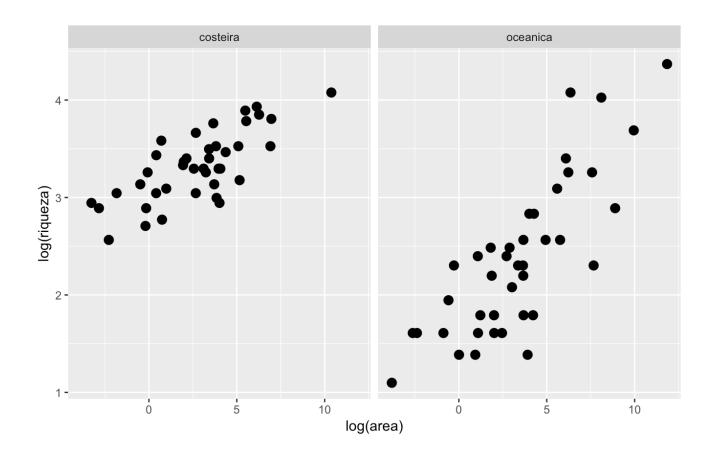
Exercício 4

- 1. Adicione uma linha de tendência ao gráfico abaixo. O que aconteceu e o que isso representa?
- 2. Se você quisesse que houvesse apenas uma linha de tendência, como deveríamos desenhar a figura?
- 3. Modifique as características da linha de tendência que você adicionou, mapeando ela à qualquer variável que você deseje.
- 4. O que acontece quando invertemos a sequência como os **geom** são adicionados?

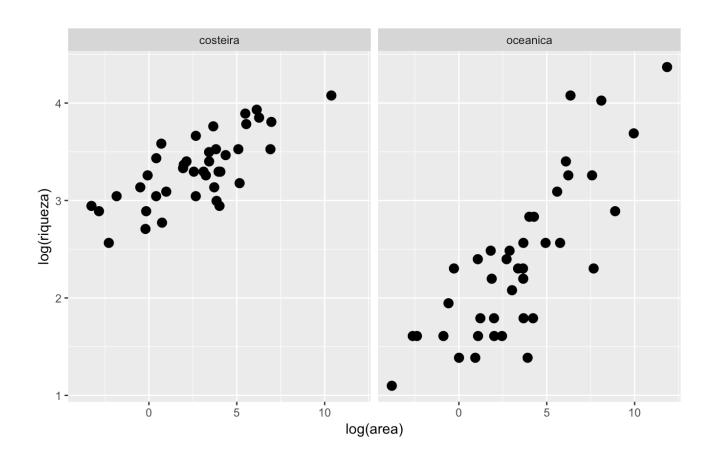
```
ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza), colour = ilha)) + geom_point(size = 3)
```

- · Muitas vezes queremos desenhar uma figura contendo múltiplos painéis, um para cada nível ou combinação de níveis de uma dada variável.
- O ggplot2 oferece duas funções que permitem mapear estes painéis em múltiplos facets. No entanto, note que aqui o que estamos fazendo é dividir uma mesma informação entre múltiplos painéis, e não desenhar informações diferentes em cada painel!
 - facet_wrap: permite que se determine de que forma os painéis serão distribuídos entre linhas e colunas. É uma função bastante flexível.
 - facet_grid: não permite que os painéis sejam distribuídos entre linhas e colunas, que são determinados de acordo com a quantidade de níveis de cada variável que se está mapeando aos painéis.

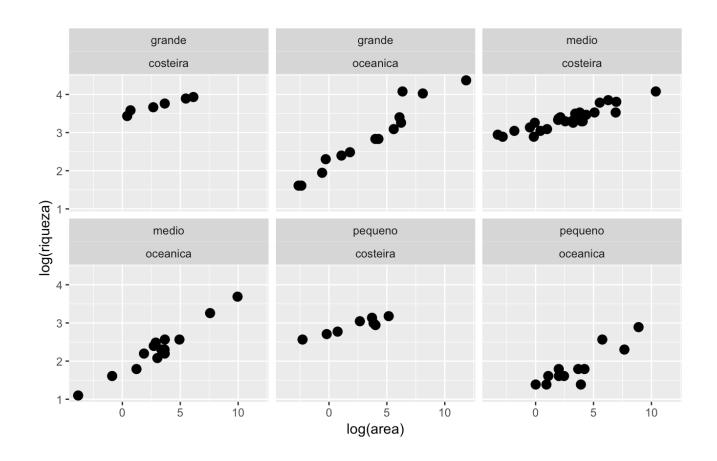
```
ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza))) +
  facet_wrap(~ ilha) +
  geom_point(size = 3)
```



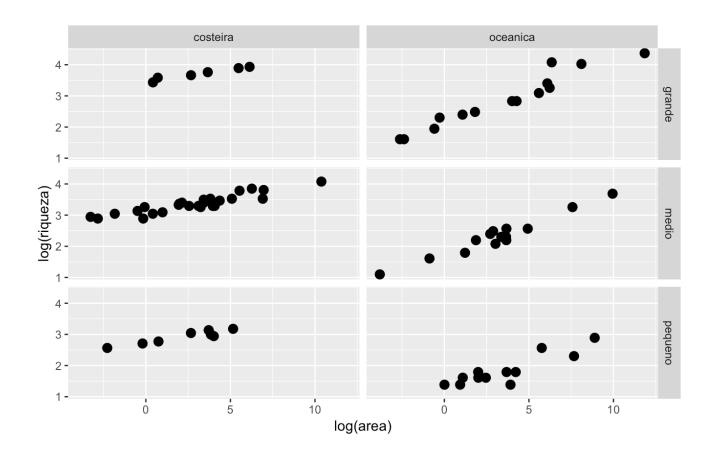
```
ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza))) +
  facet_grid(~ ilha) +
  geom_point(size = 3)
```



```
ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza))) +
  facet_wrap(arquipelago ~ ilha) +
  geom_point(size = 3)
```



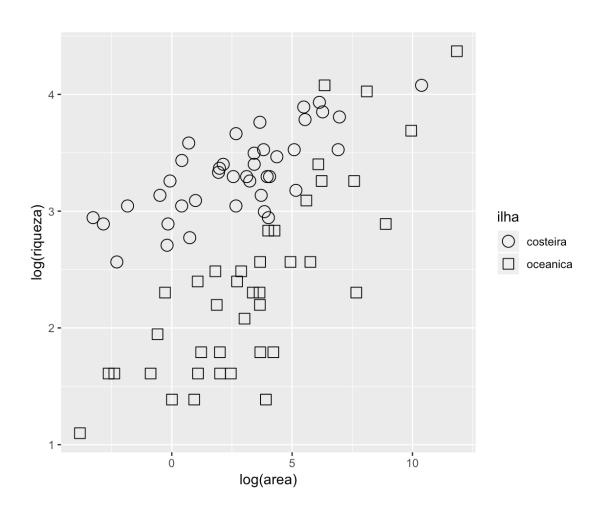
```
ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza))) +
  facet_grid(arquipelago ~ ilha) +
  geom_point(size = 3)
```

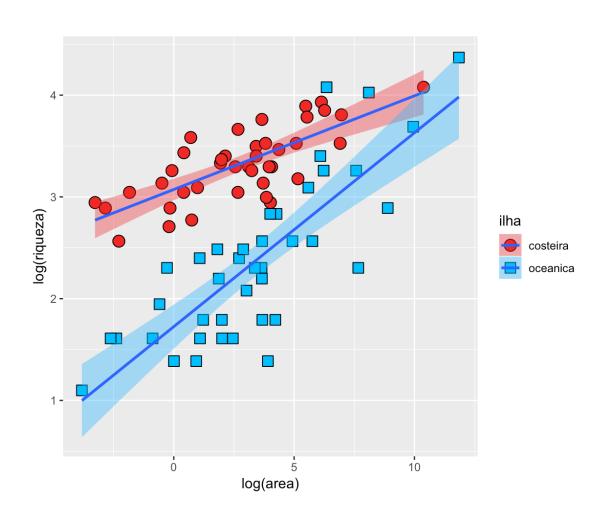


- Muito do que podemos fazer manipulando a estrutura estética do que queremos desenhar só diz o que será mapeado, mas não nos permite determinar exatamente de que forma queremos que cada característica mapeada seja representa.
- Toda a personalização do que é mapeado é feita através de camadas que descrevem a escala da figura:
 - scale_fill_?: modifica o preenchimento do objeto (fill) de forma determinada pelo usuário;
 - scale_colour_?: modifica a cor dos pontos ou das bordas do objeto geométrico (colour) de forma determinada pelo usuário;
 - scale_shape_?: modifica o formato dos pontos (shape) de forma determinada pelo usuário;
 - scale_size_?: modifica o tamanho dos pontos (size) de forma determinada pelo usuário;
 - scale_alpha_?: modifica a transparência (alpha) de forma determinada,

· Para personalizar grande parte destas escalas é necessário que aquilo que ela modifica tenha sido mapeado à alguma unidade estética.

```
\label{eq:ggplot} \begin{split} & \text{ggplot(data = ilhas, mapping = aes(x = log(area), y = log(riqueza), shape = ilha)) +} \\ & \text{geom\_point(size = 4) +} \\ & \text{geom\_smooth(method = "lm") +} \\ & \text{scale\_shape\_manual(values = c(21, 22))} \end{split}
```



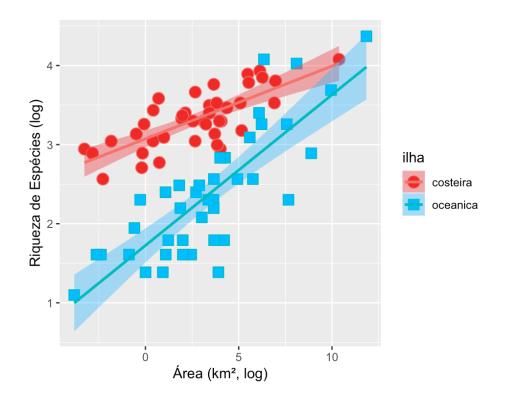


Exercício 5

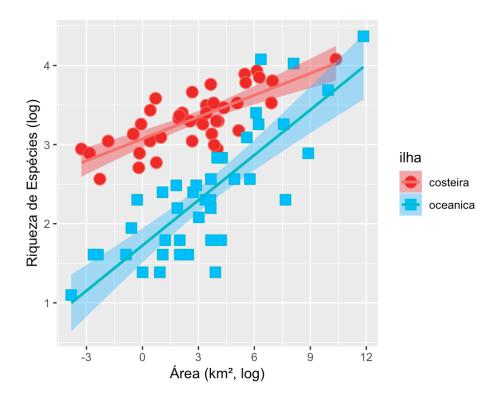
- 1. Customize o boxplot que apresenta de que forma a riqueza de espécies variam em função do tipo de ilha, mas fazendo um painel para cada tamanho de arquipélago e utilizando as funções scale.
 - Dica: o intuito é que esta customizando leve o gráfico a ficar apresentável e adequado para uma publicação, tese, documento ou qualquer coisa similar. Para tanto, é essencial que ela seja visualmente agradável e autoexplicativa!

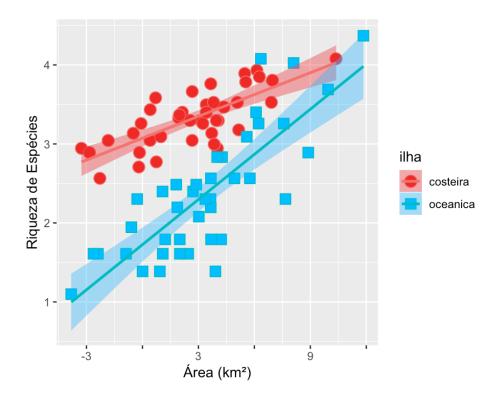
· Podemos utilizar as funções scale_x_? e scale_y_? para realizar diversos tipos de manipulação aos eixos x e y.

```
## adicionando um título adequado a cada eixo
figura +
   scale_x_continuous(name = "Área (km², log)") +
   scale_y_continuous(name = "Riqueza de Espécies (log)")
```



```
## modificar a sequência de números de um dos eixos
figura +
   scale_x_continuous(name = "Área (km², log)", breaks = seq(from = -3, to = 12, by = 3)) +
   scale_y_continuous(name = "Riqueza de Espécies (log)")
```



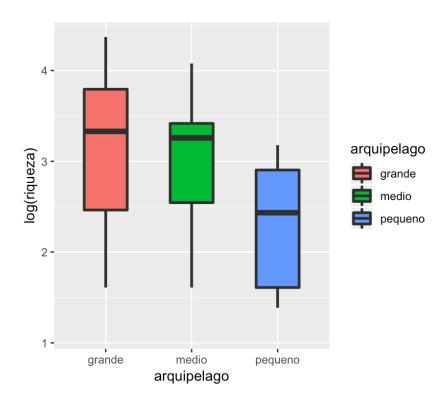


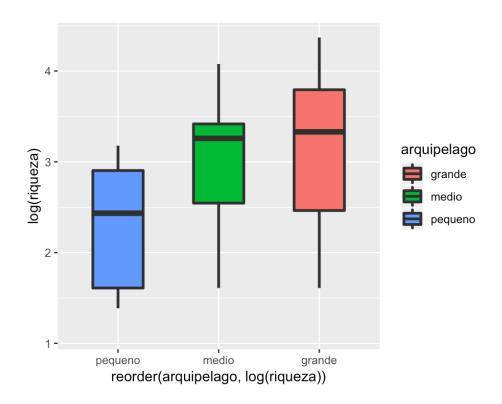
Exercício 6

1. Customize os eixos do boxplot que você criou no último exercício.

- Quando criamos figuras onde os valores de um dos eixos é discreto/categórico, o R vai utilizar como sequência a ordem alfabética (ou numérica) desta variáveil. No entanto, muitas vezes, a ordem alfabética não condiz com a magnitude ou efeito daquilo que queremos demonstrar e, portanto, precisamos modificar este padrão imposto pelo R.
- · Existem duas formas principais de fazer isso.

```
ggplot(data = ilhas, mapping = aes(x = arquipelago, y = log(riqueza), fill = arquipelago)) + geom_boxplot(outlier.colour = NA, width = 0.5, size = 1)
```

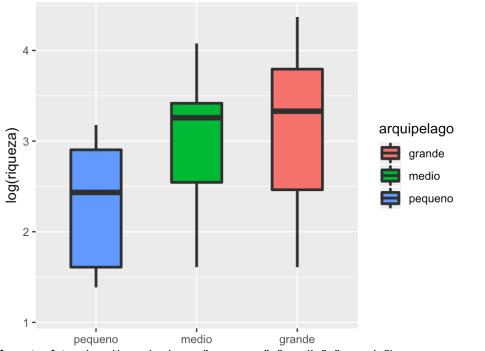




Personalizando o aspecto visual do geom e da figura

```
# através da função fct_relevel, disponível no pacote forcats

ggplot(data = ilhas, mapping = aes(
    x = forcats::fct_relevel(arquipelago, "pequeno", "medio", "grande"),
    y = log(riqueza), fill = arquipelago)) +
    geom_boxplot(outlier.colour = NA, width = 0.5, size = 1)
```



forcats::fct relevel(arquipelago, "pequeno", "medio", "grande")

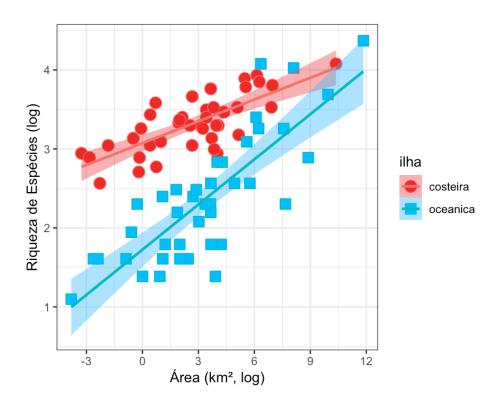
66/94

Uma figura-padrão, antes de prosseguirmos

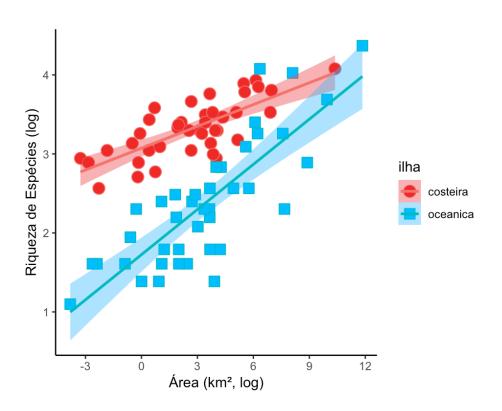
- Um importante aspecto negligenciado por grande parte das pessoas que acabam usando o ggplot2 é esse fundo cinza e grids, que são legais para explorar visualmente os dados, mas são péssimos para uma publicação.
- Esses e outros aspectos visuais gerais de um gráfico do ggplot2 são o tema dele, sendo controlados por uma função de mesmo nome theme.
- Sempre modifique e edite o tema que você usa ao criar uma figura do ggplot!

• Existem muitos temas pré-definidos disponíveis no ggplot2 quando você carrega o pacote.

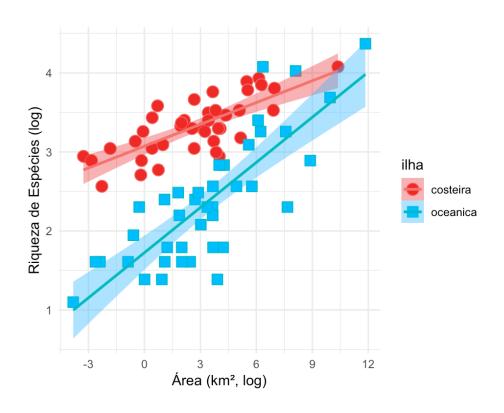
```
figura +
  theme_bw()
```



```
figura +
  theme_classic()
```



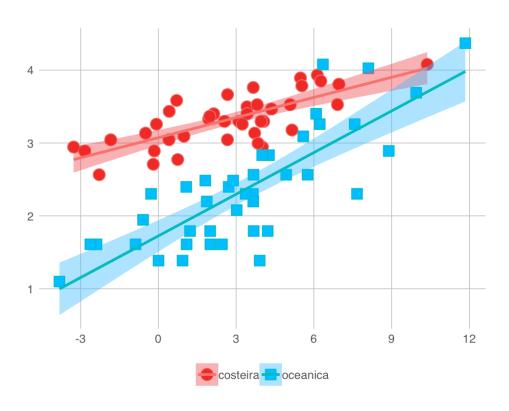
```
figura +
  theme_minimal()
```



• E existem outros temas pré-definidos disponíveis em outros pacotes, como no ggthemes.

```
library(ggthemes)
figura +
  theme_base()
```

```
figura +
  theme_excel_new()
```

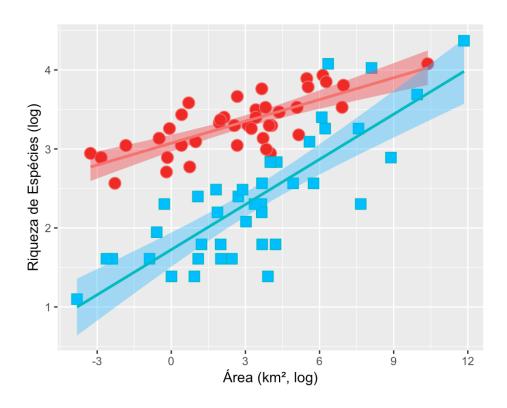


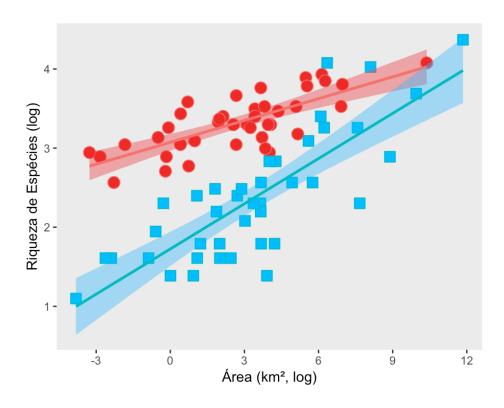
 Mas como tudo no ggplot2, o ideal é sempre personalizarmos aquilo que estamos desenhando. Para modificar o tema desta forma, precisamos modificar os padrões de valores que existe dentro da função theme, adicionando esta camada de personalização à nossa figura.

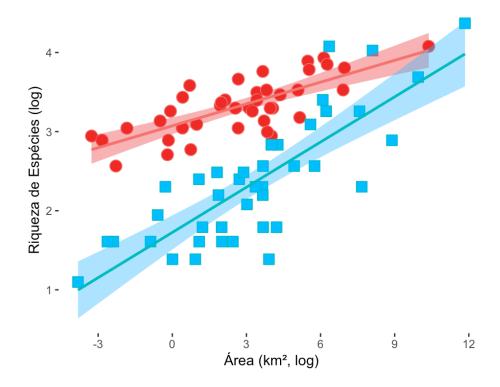
theme()

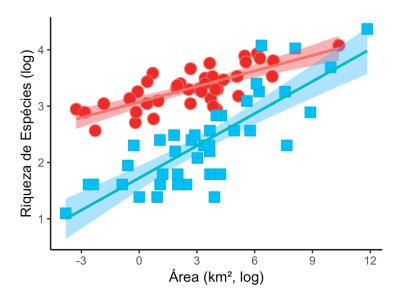
- · Todos os elementos do **tema** são manipulados de acordo com a sua natureza:
 - element_text: elementos textuais;
 - element_rect: elementos que têm a forma de um retângulo;
 - element_line: elementos que têm a forma de linha;
 - element_blank: suprime uma opção.

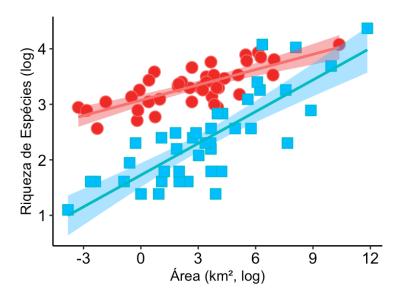
```
figura +
  theme(legend.position = "none")
```

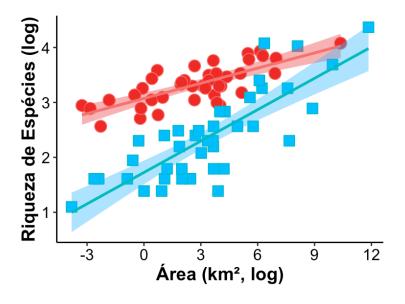








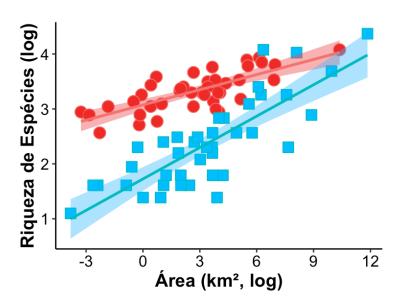




 O ggplot2 também permite que coloquemos as especificações do tema que personalizamos em um objeto, o qual podemos adicionar diretamente à figura que criamos.

· A vantagem disso é que definimos uma única vez um tema e podemos empregá-lo em tantas figuras quanto quisermos.

```
figura <- figura +
  meu_tema
figura</pre>
```



Exportando figuras do ggplot2

 Podemos exportar uma figura que criamos através do ggplot2 utilizando a função ggsave.

```
ggsave(filename = "especie_area.png", # nome/diretorio onde a figura será salva
    plot = figura, # objeto que contém a figura que você quer exportar
    width = 80, height = 80, units = "mm", # tamanho final da figura
    dpi = 150 # qualidade da imagem
    )
```

Exercício 7

1. Personalize o tema do boxplot que você tem trabalhado nos exercícios anteriores, e exporte ele para algum diretório no seu computador.

Integrando o ggplot2 ao tidyverse

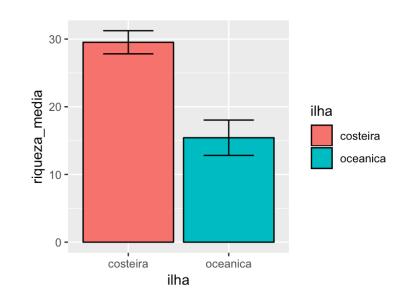
- Uma das figuras que normalmente queremos fazer é aquela onde apresentamos o valor da média e do erro padrão de acordo com diferentes níveis de uma variável categórica.
- Uma forma de fazer isso no ggplot2 é fornecendo uma tabela que contenha estes valores para a função ggplot, e associando o geom_bar ao geom_errorbar.
- Este requerimento impõem então uma tarefa prévia para criarmos este tipo de figura a partir da tabela de dados que normalmente temos, pois precisamos calcular estes sumários estatísticos antes de criar a figura.
- · Neste sentido, podemos utilizar as mesmas técnicas de manipulação, limpeza e processamento de dados que vimos nas aulas anteriores.

Exercício 8

1. Calcule o valor médio e o erro padrão da riqueza de espécies por tipo de ilha, e coloque os resultados deste processamento no objeto **sumario**.

Integrando o ggplot2 ao tidyverse

· Agora, com essa tabela de dados, podemos criar a figura que queremos.



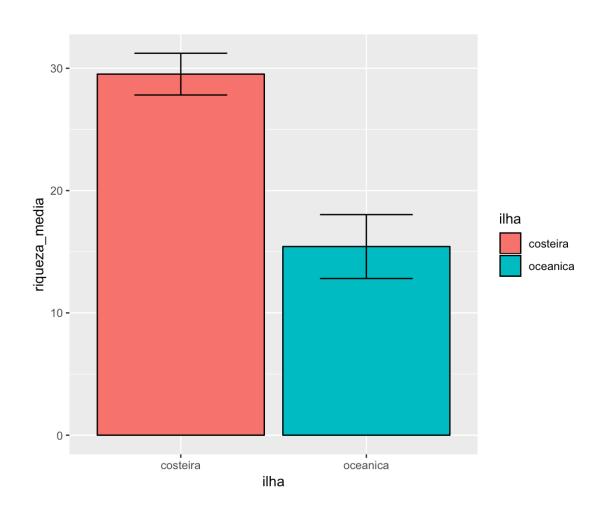
Exercício 9

- · Personalize a figura anterior:
 - Modificando a cor da barra que cada categoria recebe;
 - Editando os nomes e os valores dos eixos x e y, respectivamente;
 - Editando o título dos eixos x e y;
 - Removendo o espaço que aparece abaixo do 0 no eixo y.

Integrando o ggplot2 ao tidyverse

- Note, no entanto, que o ggplot2 é parte integrante do tidyverse, que foi todo pensado com a finalidade de encurtar a distância entre a ideia e o resultado.
- Portanto, podemos integrar todo o cálculo prévio da média e erro ao uso da função ggplot.

Integrando o ggplot2 ao tidyverse



Uma mensagem final

- Utilize o ggplot2 como uma ferramenta para a análise exploratória e visualização dos dados, mas não utilize diretamente o resultado daquilo que você produz através dele nas suas publicações.
- O principal motivo para isso é que muito do que queremos mostrar visualmente em uma publicação são os resultados das análises estatísticas, que descrevem a relação entre as variáveis considerando toda a dependência numérica e outras peculiaridades que existem nos seus dados.
- Nesse sentido, produza os resultados numéricos das suas análises estatísticas e utilize eles para criar as figuras no ggplot2. Veremos como fazer isso na próxima aula.

Exercício 10

- · Utilizando o conjunto de dados gapminder:
 - Calcule o GDP per capita médio por continente considerando apenas os dados do ano de 2007.
 - Crie uma figura demonstrando como variou o tamanho da população brasileira ao longo do tempo.
 - Crie uma figura demonstrando de que forma a expectativa de vida varia ao longo do tempo para cada país, mas dividindo os padrões em diferentes painéis de acordo com o continente.

Mais sobre o ggplot2

- No livro ggplot2: http://ggplot2.org/book/;
- No site: http://ggplot2.tidyverse.org/reference/;
- · No livro "R for Data Science": http://r4ds.had.co.nz/data-visualisation.html;
- · O Google.